

클린업 2주차

3팀 선형대수학

황정현
고경현
김지민
반경림
전효림

INDEX

0. 지난주 REVIEW

1. 행렬식

2. 공간개념

3. 투영벡터

4. 선대, 회귀와 만나다



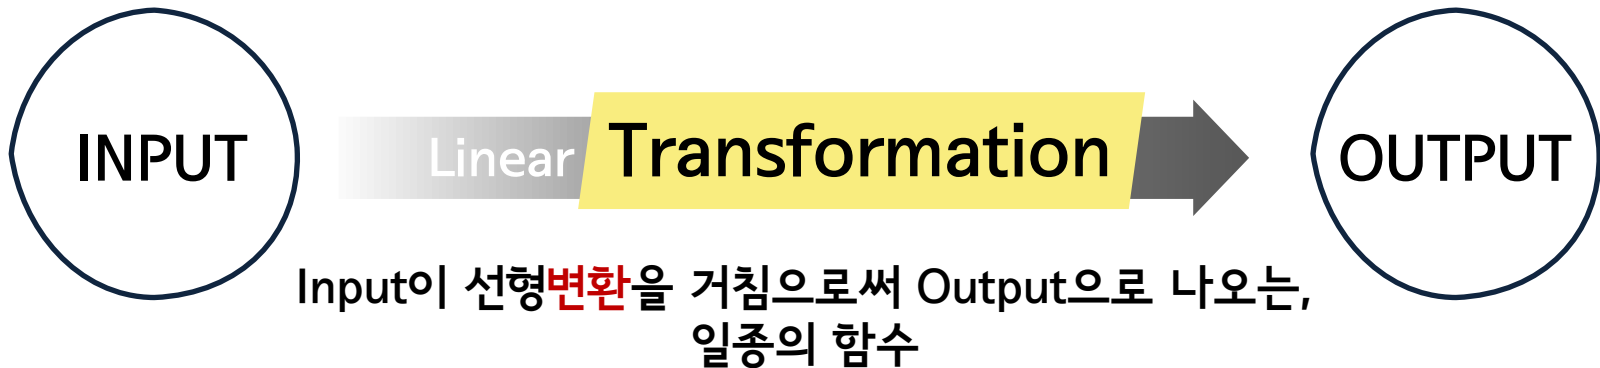
선형대수

통계 분석의 시작점

선형성을 바탕으로
선형변환과 그때의 공간에 대해 연구하는
대수학의 한 분야



선형 '변환'의 의미


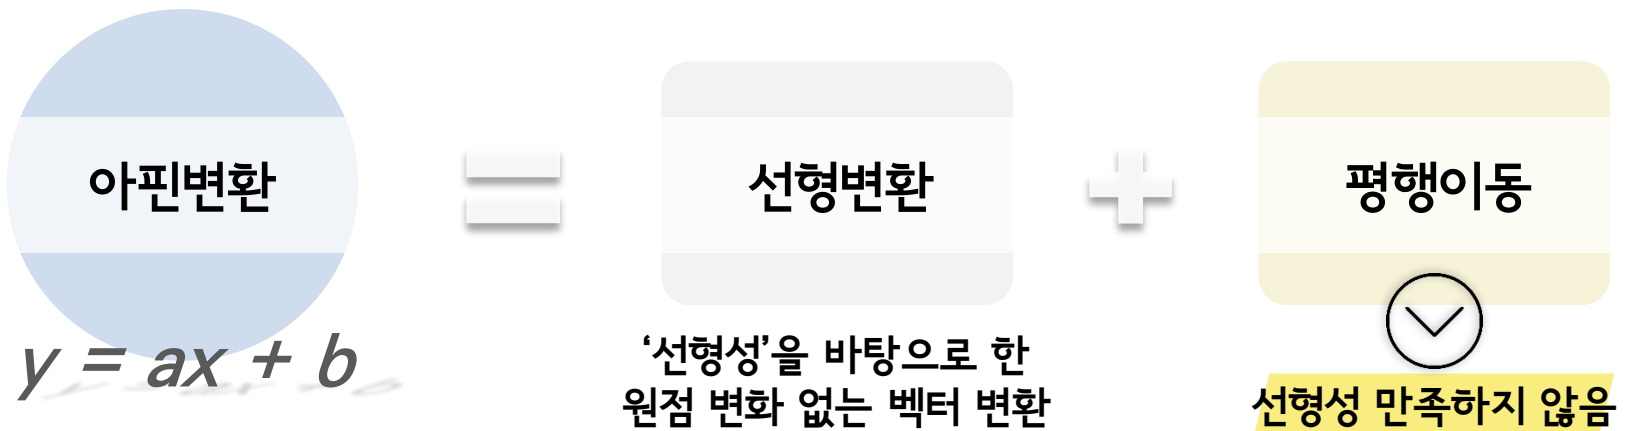


선형방정식 $Ax = b$ 를 '변환'의 관점에서 이해해보자!


$$\begin{matrix} A \\ \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} \end{matrix} \begin{matrix} x \\ \begin{pmatrix} x \\ y \end{pmatrix} \end{matrix} = \begin{matrix} b \\ \begin{pmatrix} 0 \\ 3 \end{pmatrix} \end{matrix}$$

x라는 input에 A라는 변환을 거쳐 b라는 새로운 output 반환


Affine transformation



변환 전



선형변환



아핀변환

1

행렬식



$n \times n$ 의 정사각행렬에 스칼라를 대응시키는 일종의 함수

$$\det(A) \mid \det A$$

기하학적 의미

행렬식과 선형변환


행렬식의 쓰임

기하학적 의미

- $|\det(A)|$: 행렬의 열벡터로 만들어지는 공간의 크기


2 x 2
행렬

행렬의 열벡터로
만들어지는
평행사변형의 넓이



3 x 3
행렬

행렬의 열벡터로
만들어지는
직육면체의 부피



선형변환으로의 해석

- 선형변환 전후의 넓이 관계 설명

지난주 이야기!



‘선형변환’의 관점에서 바라본 선형방정식 $Ax = b$

$$\begin{matrix} A & x \\ \begin{pmatrix} 2 & -3 \\ 1 & 1 \end{pmatrix} & \begin{pmatrix} 1 \\ 1 \end{pmatrix} \end{matrix} = \begin{matrix} b \\ \begin{pmatrix} -1 \\ 2 \end{pmatrix} \end{matrix}$$

벡터 x 에 행렬 A 를 곱하는 선형변환을 통해 벡터 b 만들

input

벡터 x 가 만드는
공간의 넓이

Linear Transformation

$|\det(A)|$ 배 변화

output

벡터 b 가 만드는
공간의 넓이


선형변환으로의 해석

- 선형변환 전후의 넓이 관계 설명

벡터 x

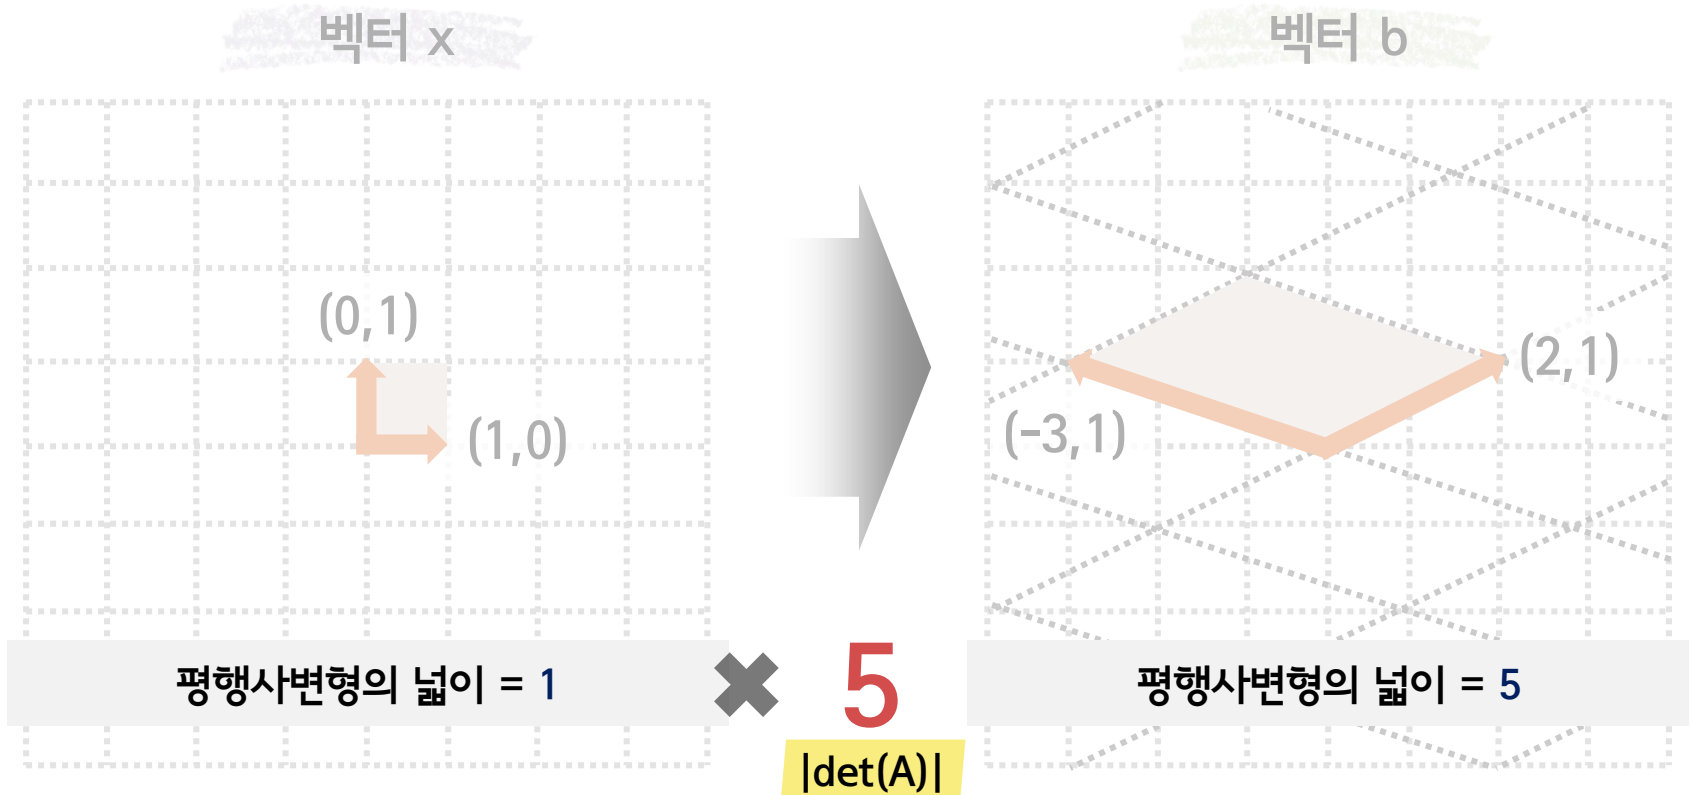


벡터 b



선형변환으로의 해석

- 선형변환 전후의 넓이 관계 설명



선형변환으로의 해석

- 선형변환 전후의 넓이 관계 설명



선형방정식 $Ax = b$ 에서

(\mathbb{R}^2) 변환 후(b) 넓이 = $|\det(A)| \cdot$ 변환 전(x) 넓이

(\mathbb{R}^3) 변환 후(b) 부피 = $|\det(A)| \cdot$ 변환 전(x) 부피

평행사변형의 넓이 = 1

× 5

$|\det(A)|$

평행사변형의 넓이 = 5

선형변환으로의 해석

Q




$\det(A)$ 에 **절댓값**을 씌우는 이유는 무엇인가요?

$\det(A)$ 의 부호

=

공간의 **반전 여부**

면적 변화는 **4배**로 같지만 좌우가 반전됨




선형변환으로의 해석

Q

그렇다면 $\det(A)$ 가 0인 것은 무엇을 뜻하나요?



선형변환을 통해 **공간이 압축**되었다!



차원이 바뀌면 기존 공간에서의 부피/넓이는 0이 됨

행렬식의 쓰임


1 역행렬 존재 유무 판별




A^{-1}
역행렬이
존재한다



- $Ax = b$ 가 유일한 해를 갖는다(unique)
- x 와 Ax 가 서로 일대일 대응이다



공간압축
선형변환



~~A^{-1}~~
역행렬이
존재하지
않는다


행렬식의 쓰임

1 역행렬 존재 유무 판별

A^{-1}
역행렬이
존재한다

=

- $Ax = b$ 가 유일한 해를 갖는다(unique)
- x 와 Ax 가 서로 일대일 대응이다



공간압축
선형변환

$$\det(A) = 0$$

~~A^{-1}~~
역행렬이
존재하지
않는다

행렬식의 쓰임

1 역행렬 존재 유무 판별

A^{-1}
역행렬이
존재한다

=

- $Ax = b$ 가 유일한 해를 갖는다(unique)
- x 와 Ax 가 서로 일대일 대응이다



공간압축
선형변환


$$\det(A) = 0$$

~~A^{-1}~~
역행렬이
존재하지
않는다

행렬식의 쓰임

2 Cramer's Rule로 해 구하기

- $\det(A) \neq 0$ 일 때, 즉 A 의 역행렬이 존재할 때 Cramer's Rule 활용



선형방정식 $\begin{cases} 8x + 5y = 2 \\ 2x - 4y = -10 \end{cases}$ 을 풀어보자!

$$\begin{pmatrix} \overset{A}{8} & \overset{5}{5} \\ 2 & -4 \end{pmatrix} \begin{pmatrix} \overset{x}{x} \\ \overset{y}{y} \end{pmatrix} = \begin{pmatrix} \overset{b}{2} \\ -10 \end{pmatrix}$$

$$\det(A) = -32 - 10 = -42$$



$$x = \frac{\begin{vmatrix} 2 & 5 \\ -10 & -4 \end{vmatrix}}{\det(A)} = \frac{-8 - (-50)}{-42} = -1$$

$$y = \frac{\begin{vmatrix} 8 & 2 \\ 2 & -10 \end{vmatrix}}{\det(A)} = \frac{-80 - 4}{-42} = 2$$

2

공간 개념

선형부분공간

벡터공간

선형부분공간

span

column space

선형부분공간

벡터공간

선형부분공간

span

column space

- 여러 벡터들이 모여 형성한 공간 (\mathbb{R}^n)
- 벡터에 대한 합과 상수배가 연산법칙 만족


 벡터의 합

$$\begin{aligned}
 a + b &= b + a \\
 (a + b) + c &= a + (b + c) \\
 a + 0 &= a \\
 a + (-a) &= 0
 \end{aligned}$$

- 교환법칙
- 결합법칙
- 항등원
- 역원


 상수배

$$\begin{aligned}
 c(a + b) &= ca + cb \\
 (c + k)a &= ca + ka \\
 c(ka) &= (ck)a \\
 1a &= a
 \end{aligned}$$

선형부분공간

subspace

벡터공간

선형부분공간

span

column space

\mathbb{R}^n

선형부분공간

- 벡터공간 안의 몇 가지 벡터 집합으로 이루는 또다른 부분 벡터공간



선형 조건



0벡터(원점)가 존재한다

선형부분공간 내 벡터에 다른 벡터를 **합**한 것도 선형부분공간에 존재한다

선형부분공간 내 벡터에 **상수를 곱**한 것도 선형부분공간에 존재한다

선형부분공간

벡터공간

선형부분공간

subspace

span

column space

\mathbb{R}^n

선형부분공간

- 벡터공간 안의 몇 가지 벡터 집합으로 이루는 또다른 부분 벡터공간



선형 조건



0벡터(원점)가 존재한다

선형부분공간 내 벡터에 다른 벡터를 합한 것도 선형부

선형부분공간 내 벡터에 상수를 곱한 것도 선형부분공간에 존재한다



어떤 벡터에 **0**을 곱하면
항상 0이 되므로
반드시 원점을 포함

선형부분공간

subspace

벡터공간

선형부분공간




span

column space



2차원 공간에서 축을 포함한 제1사분면은

선형부분공간이 될 수 있을까?



선형부분공간

벡터공간

선형부분공간

subspace




span

column space



2차원 공간에서 축을 포함한 제1사분면은

선형부분공간이 될 수 있을까?



선형부분공간이 아니다! 💧

선형부분공간

벡터공간

선형부분공간




subspace

span

column space

그렇다면 2차원 공간에서의 직선 l 은

선형부분공간이 될 수 있을까?



선형부분공간

벡터공간

선형부분공간




subspace

span

column space

그렇다면 2차원 공간에서의 직선 l 은

선형부분공간이 될 수 있을까?



선형부분공간이다!



선형부분공간


벡터공간

선형부분공간

span

column space

- 벡터 a_1, a_2, \dots, a_n 의 모든 선형결합이 속하는 선형부분공간



2차원 공간의 선형부분공간

모든 v 에 대한 조합

$\text{span}\{v\}$

선형부분공간


벡터공간

선형부분공간

span

column space

- 벡터 a_1, a_2, \dots, a_n 의 모든 선형결합이 속하는 선형부분공간



v_1 과 v_2 의 합과 상수배로
만든 모든 조합

$\text{span}\{v_1, v_2\}$

3차원 공간에서
원점을 지나는 평면

선형부분공간

벡터공간

선형부분공간


span

column space

• 벡터 a_1, a_2, \dots, a_n 의 모든 선형결합이 속하는 선형부분공간
 span 은 사용하는 벡터에 따라

모든 공간을 채움

직선, 평면 등의 형태인 선형부분공간



특정 공간의 특정 형태

$\text{span}\{v_1, v_2\}$

벡터들의 가능한 **선형결합의 모음**을 한 공간에 몰아넣은 것

선형부분공간


벡터공간

선형부분공간

span

column space

- 행렬 A 의 열벡터의 연산으로 만드는 공간
- 행렬 A 의 **열벡터의 span**



선형부분공간


벡터공간

선형부분공간

span

column space

- 행렬 A 의 열벡터의 연산으로 만드는 공간
- 행렬 A 의 **열벡터의 span**



$Ax = b$ 의 해가 있다

$col(A)$ 가 모든 Ax 를 포함한다

벡터 b 가 $col(A)$ 에 있다

벡터 b 가 $span\{a\}$ 에 있다

선형부분공간

벡터공간

선형부분공간

span

column space

- 행렬 A 의 열벡터의 연산으로 만드는 공간
- 행렬 A 의 **열벡터의 span**

$Ax = b$ 가 **모든** b 에 대해 해를 갖는다

모든 b 에 대한 $\text{col}(A)$ 가 존재한다

$\text{col}(A)$ 가 모든 b 를 표현한다

$\text{col}(A)$ 가 **벡터공간(\mathbb{R}^n)**이다

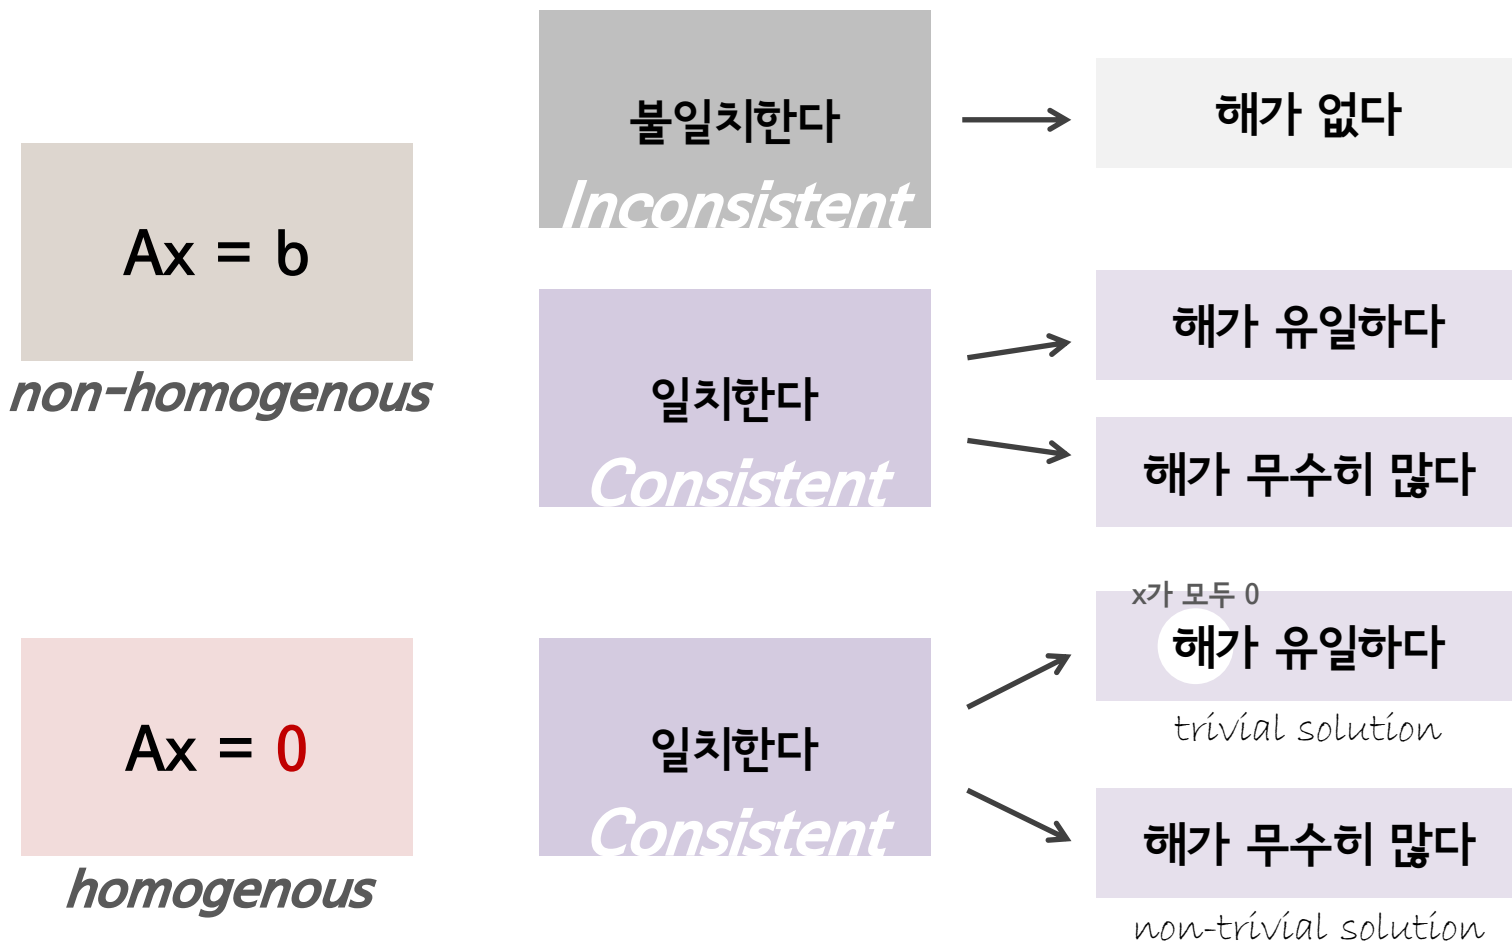
$Ax = b$ 의 해가 있다

$\text{col}(A)$ 가 모든 Ax 를 포함한다

벡터 b 가 $\text{col}(A)$ 에 있다

벡터 b 가 $\text{span}\{a\}$ 에 있다

Null space



Null space

영공간
Null Space

해가 없다



$Ax = 0$ 을 만족하는 해 x 가 이루는 공간,
즉 homogenous한 방정식의 해의 집합

$$Ax = 0$$

homogenous

일치한다

Consistent x 가 모두 0

해가 유일하다

trivial solution

해가 무수히 많다

non-trivial solution

Null space

$$\begin{matrix} & A & \\ \begin{pmatrix} 1 & 0 & 1 \\ 1 & 1 & 2 \\ 0 & 1 & 1 \end{pmatrix} & \begin{pmatrix} x \\ y \\ z \end{pmatrix} & = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \end{matrix}$$

Null
space $Ax = 0$ 을 만족시키는 **해**들을 모아 형성한 공간

0벡터



해벡터끼리의 합



해벡터의 상수배



선형부분공간

방정식의 해벡터가 \mathbb{R}^n 그것의 null space는 \mathbb{R}^n 의 선형부분공간

기저

1 선형독립 *independence*

- $c_1x_1 + c_2x_2 + \cdots + c_nx_n = 0$ 에서 c 가 모두 0인 경우를 제외한 어떠한 c_i 의 조합으로도 식이 성립되지 않는 경우



$$A x = 0$$

- 선형방정식을 만족하는 벡터 x 가 오직 0벡터뿐인 경우




- Null space에 0벡터만 있는 경우


기저

1 선형독립 *independence*

$$c_1v_1 + c_2v_2 = 0$$



0벡터가 아닌 벡터에 의해
식이 성립됨




c가 모두 0인 경우를 제외하고는
두 벡터를 이용하여 0을 만들 수 없음


기저

1 선형독립 *independence*

$$c_1v_1 + c_2v_2 = 0$$



종 속



독 립



기저

2 기저 Basis

span



선형독립

어떤 공간을 구성하는 span 벡터의 **최소** 집합벡터공간을 **효율적**으로 표현할 수 있는 벡터들(span)어떤 공간을
span하는
기저는
유일하지 **않음**

기저

3 Null space의 기저

- 자유변수를 상수로 하는 선형조합의 벡터

$$A = \begin{pmatrix} 1 & 1 & 0 & 2 \\ -2 & -2 & 1 & -5 \\ 1 & 1 & -1 & 3 \\ 4 & 4 & -1 & 9 \end{pmatrix}$$

행렬 A를 RREF로 정리 후
해와 기저를 구해보자!



$$x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} -x_2 - 2x_4 \\ x_2 \\ x_4 \\ x_4 \end{pmatrix} = s \begin{pmatrix} -1 \\ 1 \\ 0 \\ 0 \end{pmatrix} + t \begin{pmatrix} -2 \\ 0 \\ 1 \\ 1 \end{pmatrix}$$

자유변수 기저

기저

3 Null space의 기저

- 자유변수를 상수로 하는 선형조합의 벡터

null space의
기저 개수



자유변수 개수



$n - (\text{pivot 개수})$

$$x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} -x_2 - 2x_4 \\ x_2 \\ x_4 \\ x_4 \end{bmatrix} = s \begin{bmatrix} -1 \\ 1 \\ 0 \\ 0 \end{bmatrix} + t \begin{bmatrix} -2 \\ 0 \\ 1 \\ 1 \end{bmatrix}$$

자유변수 기저

기저

4 Column space의 기저

- RREF의 **pivot**이 위치하는 원래 행렬의 열

column space의
기저 개수



pivot의 개수


$$A = \begin{pmatrix} 1 & 1 & 0 & 2 \\ -2 & -2 & 1 & -5 \\ 1 & 1 & -1 & 3 \\ 4 & 4 & -1 & 9 \end{pmatrix}$$

col(A)의 기저

$$R = \begin{pmatrix} 1 & 1 & 0 & 2 \\ 0 & 0 & 1 & -1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

독립

차원과 rank



	Null space	Column space
<i>dimension</i>	자유변수 개수 pivot이 없는 열 개수	pivot 개수

$\text{rank}(A)$

3

투영벡터

벡터의 크기와 거리


\mathbb{R}^n 의 벡터 $x = (x_1, x_2, \dots, x_n)$ 에 대하여,

벡터의 크기

norm | length | $\|x\|$

$$\sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

: 점 $P(x_1, x_2, \dots, x_n)$ 와 원점 사이 거리



점 P와 Q 사이의 거리

$$\|x - y\|$$

$$\sqrt{(x_1 - y_1)^2 + \dots + (x_n - y_n)^2}$$

내적 (inner product, dot product)

\mathbb{R}^n 의 벡터 $x = (x_1, x_2, \dots, x_n)$, $y = (y_1, y_2, \dots, y_n)$ 에 대하여,

내적 공식

$$x \cdot y$$

$$x_1y_1 + x_2y_2 + \dots + x_ny_n$$

$$x = \begin{bmatrix} 3 \\ 2 \\ 1 \end{bmatrix} \quad y = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix} \Rightarrow \begin{bmatrix} 3 & 2 & 1 \end{bmatrix}^{x^T} \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}^y = \begin{bmatrix} 14 \end{bmatrix}$$


1 x 1의 상수

원소의 개수가 같은 x, y


직교 (orthogonality)

- 벡터가 서로 수직으로 만나는 경우

1 기하학적 Geometrical



2 수식적 Mathematical



$$u \cdot v = 0$$

$$u^T v = \begin{pmatrix} 2 & 2 \end{pmatrix} \begin{pmatrix} 3 \\ -3 \end{pmatrix} = 0$$

직교 (orthogonality)

- 벡터가 서로 수직으로 만나는 경우


orthogonal set

$$u_1 = \begin{pmatrix} 3 \\ 1 \\ 1 \end{pmatrix}$$

$$u_2 = \begin{pmatrix} -1 \\ 2 \\ 1 \end{pmatrix}$$

$$u_3 = \begin{pmatrix} -1/2 \\ -2 \\ 7/2 \end{pmatrix}$$



선
형
독
립



투영벡터 (Projection)

투영

하나의 벡터를 다른 벡터로 옮겨서 표현



투영벡터 (Projection)



벡터 b 를 직선 a 위의
벡터로 매핑

=

벡터 b 의 직선 공간으로의
공간압축

=

공간압축
선형변환



투영벡터 (Projection)

벡터 b 를 직선 a 위의
벡터로 매핑


벡터 b 의 직선 공간으로의
공간압축

공간압축
선형변환



벡터 b 의
 $\text{span}\{a\}$ 상의
정사영
'Proj_a'

실제값(b)과 예측값(p)의 차이인 e 와
벡터 a 가 직교함을 이용하여 계산



4

선대, 회귀를 만나다

투영벡터와 Least Square Method

해의 종류




지난주!


일치한다

Consistent

해가 유일하다




해가 무수히 많다



불일치한다

Inconsistent

해가 없다



투영벡터와 Least Square Method

해의 종류

Q

자난주!

 $AX = b$ 의 해가 없는데 ... 무엇을 연구하면 좋을까요?

- 거리 개념
- 투영 벡터


주어진 방정식을 최대한 만족하는,
해다운 것을 찾아 대신 사용하자!

A

불일치한다


Inconsistent

해가 없다



투영벡터와 Least Square Method


해의 종류



투영벡터와 Least Square Method

최소자승법

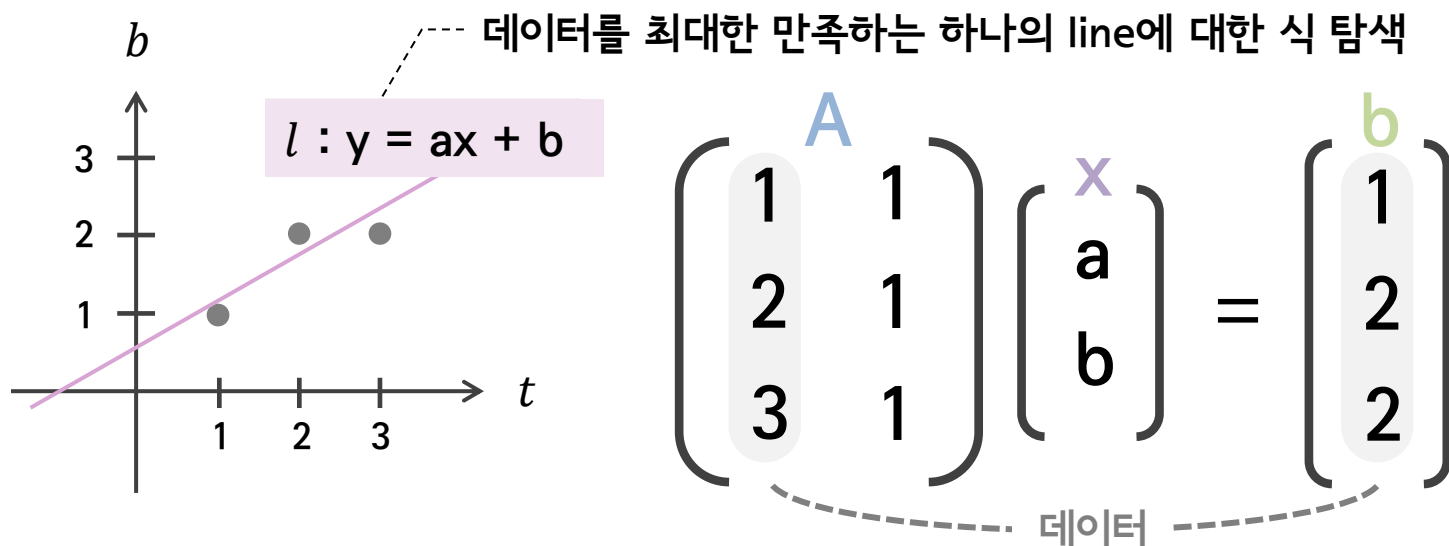
Least Square Method

 $Ax = b$ 의 해가 없는 경우 **최소 거리**를 바탕으로가장 근접한 $A\hat{x} = \hat{b}$ 의 해 \hat{x} 를 구하는 것

투영벡터와 Least Square Method

최소자승법

Least Square Method

 $Ax = b$ 의 해가 없는 경우 **최소 거리**를 바탕으로가장 근접한 $A\hat{x} = \hat{b}$ 의 해 \hat{x} 를 구하는 것


선형회귀분석



독립변수와 종속변수 간의 관계를 가장 잘 설명하는 직선을 찾는 것이 목표



실제값(y)과 예측값(\hat{y})이 비슷하도록,
즉 $y - \hat{y}$ (잔차, residual)의 제곱값을 최소화하도록!



선형회귀분석

1 회귀식 $y = \beta_0 + \beta_1 x$ 형태 바꾸기

$$\underset{A}{X} \underset{x}{\beta} = \underset{b}{y} \quad X = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} \quad y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

2 Least Square Method 적용해 간접해 구하기

$$\underset{XB \text{와 } y \text{의 최소 거리 고려}}{X} \hat{\beta} = \hat{y} \quad \Rightarrow \quad \hat{\beta} = (X^T X)^{-1} X^T y$$

선형회귀분석

1 회귀식 $y = \beta_0 + \beta_1 x$ 형태 바꾸기

꼭 기억하라구 ~ㅎ



회귀분석에서는 **Least Square Method**를 통해

회귀식 $X\beta = y$ 의 **간접해** $\hat{\beta}$ 를 구함으로써

실제값(y)과 예측값(\hat{y} , $X\hat{\beta}$)의 거리(**residual**)를

최소화하는 회귀식을 구하는 것이 목표!

$X\beta$ 와 y 의 최소 거리 고려

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

가중회귀모델

- 단순선형회귀식 •

$$y = X\beta + \varepsilon$$



residual



등분산성

$$E(\varepsilon) = 0, V(\varepsilon) = \sigma^2$$

오차항은 독립변수(X)와 무관하게 골고루 분포한다



가중회귀모델

- 단순선형회귀식 •

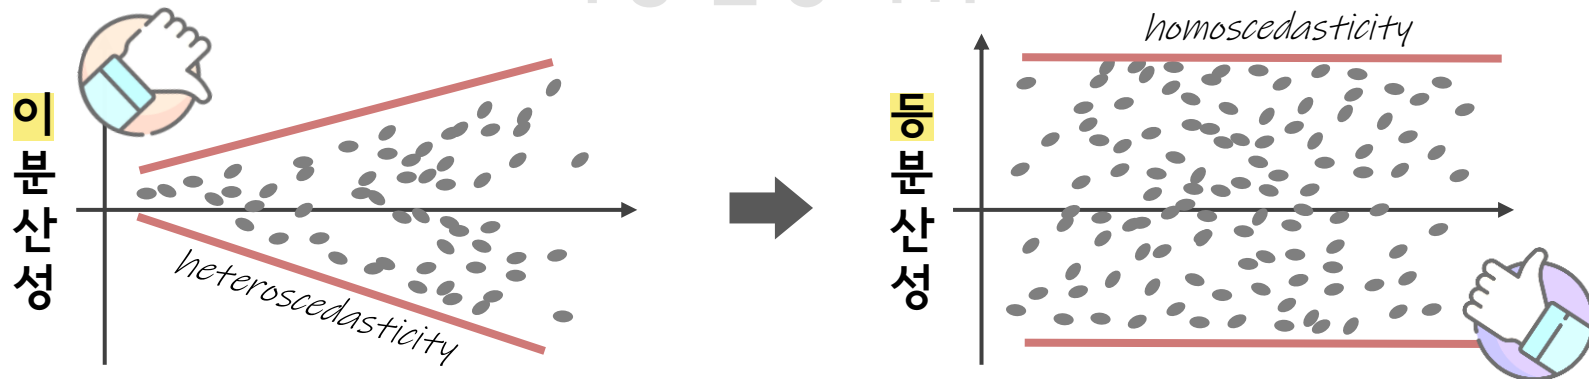
$$y = X\beta + \varepsilon$$

residual

작은 분산에 가중치를 두어

등분산성을 만족하게끔 처리한 후 회귀분석 진행

가중선형회귀



가중회귀모델

$$\begin{array}{ccc}
 \begin{pmatrix} w_1 & 0 & \cdots & 0 \\ 0 & w_1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & w_n \end{pmatrix} & \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} & \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} \\
 \textcolor{red}{W} & X & \beta
 \end{array} = \begin{array}{cc}
 \begin{pmatrix} w_1 & 0 & \cdots & 0 \\ 0 & w_1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & w_n \end{pmatrix} & \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \\
 \textcolor{red}{W} & y
 \end{array}$$

양변에 가중치를 곱한 뒤 Least Square Method를 적용해 베타계수 추정

$$\hat{\beta} = ((WX)^T WX)^{-1} (WX)^T W y$$



기존 선형회귀 모형



가중치 행렬 $\textcolor{red}{W}$

가중회귀모델



두 회귀모형의 비교



	단순선형회귀	가중회귀
SSE	$\ y - \hat{y}\ ^2 = \ y - X\hat{\beta}\ ^2$	$\ W y - W \hat{y}\ ^2 = \ W y - W X \hat{\beta}\ ^2$
β 의 해	$X^T X \hat{\beta} = X^T y$	$(W X)^T W X \hat{\beta} = (W X)^T W y$

기존 선형회귀 모형

가중치 행렬 W

!다음주 예고!

다음주에는

☀ 고유값과 고유벡터 ☀

☀ 주성분분석(PCA) ☀

☀ 특이값 분해 (SVD) ☀

☀ 계층분석법 (AHP) ☀

하고 싶습니다!!



하고 싶은 일 모두 할 수 있음 좋겠네~
하늘만큼 땅만큼 너무나 많은 꿈들~~



THANK YOU

